

Analyse Statistique HR Analytics

Licence 2 Big Data et Analyse de Données

Malek Jaafrat - May Zarriat

Mai 2026

Introduction

Ce projet consiste à réaliser une analyse statistique uni-variée, bi-variée et multi-variée du dataset HR Analytics Employee Attrition & Performance.

L'objectif est d'étudier les facteurs influençant l'attrition des employés dans une entreprise.

Source des données

Dataset : **HR Analytics Employee Attrition & Performance**

Plateforme : Kaggle

Lien : <https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset>

Importation des bibliothèques

```
library(ggplot2)
library(FactoMineR)
library(factoextra)
```

```
## Welcome to factoextra!
```

```
## Want to learn more? See two factoextra-related books at https://www.datanovia.com/en/product/practice
```

```
library(corrplot)
```

```
## corrplot 0.95 loaded
```

```
library(MASS)
```

Importation du dataset

```
data <- read.csv("WA_Fn-UseC_-HR-Employee-Attrition.csv",
                 header = TRUE,
                 stringsAsFactors = TRUE)
```

Exploration du dataset

```
dim(data)
```

```
## [1] 1470 35
```

```
names(data)
```

```
## [1] "Age" "Attrition"
## [3] "BusinessTravel" "DailyRate"
## [5] "Department" "DistanceFromHome"
## [7] "Education" "EducationField"
## [9] "EmployeeCount" "EmployeeNumber"
## [11] "EnvironmentSatisfaction" "Gender"
## [13] "HourlyRate" "JobInvolvement"
## [15] "JobLevel" "JobRole"
## [17] "JobSatisfaction" "MaritalStatus"
## [19] "MonthlyIncome" "MonthlyRate"
## [21] "NumCompaniesWorked" "Over18"
## [23] "OverTime" "PercentSalaryHike"
## [25] "PerformanceRating" "RelationshipSatisfaction"
## [27] "StandardHours" "StockOptionLevel"
## [29] "TotalWorkingYears" "TrainingTimesLastYear"
## [31] "WorkLifeBalance" "YearsAtCompany"
## [33] "YearsInCurrentRole" "YearsSinceLastPromotion"
## [35] "YearsWithCurrManager"
```

```
str(data)
```

```
## 'data.frame': 1470 obs. of 35 variables:
## $ Age : int 41 49 37 33 27 32 59 30 38 36 ...
## $ Attrition : Factor w/ 2 levels "No","Yes": 2 1 2 1 1 1 1 1 1 1 ...
## $ BusinessTravel : Factor w/ 3 levels "Non-Travel","Travel_Frequently",...: 3 2 3 2 3 2 3 3
## $ DailyRate : int 1102 279 1373 1392 591 1005 1324 1358 216 1299 ...
## $ Department : Factor w/ 3 levels "Human Resources",...: 3 2 2 2 2 2 2 2 2 ...
## $ DistanceFromHome : int 1 8 2 3 2 2 3 24 23 27 ...
## $ Education : int 2 1 2 4 1 2 3 1 3 3 ...
## $ EducationField : Factor w/ 6 levels "Human Resources",...: 2 2 5 2 4 2 4 2 2 4 ...
## $ EmployeeCount : int 1 1 1 1 1 1 1 1 1 1 ...
## $ EmployeeNumber : int 1 2 4 5 7 8 10 11 12 13 ...
## $ EnvironmentSatisfaction : int 2 3 4 4 1 4 3 4 4 3 ...
## $ Gender : Factor w/ 2 levels "Female","Male": 1 2 2 1 2 2 1 2 2 2 ...
## $ HourlyRate : int 94 61 92 56 40 79 81 67 44 94 ...
## $ JobInvolvement : int 3 2 2 3 3 3 4 3 2 3 ...
```

```
## $ JobLevel          : int  2 2 1 1 1 1 1 1 3 2 ...
## $ JobRole           : Factor w/ 9 levels "Healthcare Representative",...: 8 7 3 7 3 3 3 3 5 1
## $ JobSatisfaction   : int  4 2 3 3 2 4 1 3 3 3 ...
## $ MaritalStatus     : Factor w/ 3 levels "Divorced","Married",...: 3 2 3 2 2 3 2 1 3 2 ...
## $ MonthlyIncome     : int  5993 5130 2090 2909 3468 3068 2670 2693 9526 5237 ...
## $ MonthlyRate       : int  19479 24907 2396 23159 16632 11864 9964 13335 8787 16577 ...
## $ NumCompaniesWorked : int  8 1 6 1 9 0 4 1 0 6 ...
## $ Over18            : Factor w/ 1 level "Y": 1 1 1 1 1 1 1 1 1 1 ...
## $ OverTime          : Factor w/ 2 levels "No","Yes": 2 1 2 2 1 1 2 1 1 1 ...
## $ PercentSalaryHike  : int  11 23 15 11 12 13 20 22 21 13 ...
## $ PerformanceRating  : int  3 4 3 3 3 3 4 4 4 3 ...
## $ RelationshipSatisfaction: int  1 4 2 3 4 3 1 2 2 2 ...
## $ StandardHours     : int  80 80 80 80 80 80 80 80 80 80 ...
## $ StockOptionLevel   : int  0 1 0 0 1 0 3 1 0 2 ...
## $ TotalWorkingYears  : int  8 10 7 8 6 8 12 1 10 17 ...
## $ TrainingTimesLastYear : int  0 3 3 3 3 2 3 2 2 3 ...
## $ WorkLifeBalance    : int  1 3 3 3 3 2 2 3 3 2 ...
## $ YearsAtCompany     : int  6 10 0 8 2 7 1 1 9 7 ...
## $ YearsInCurrentRole  : int  4 7 0 7 2 7 0 0 7 7 ...
## $ YearsSinceLastPromotion : int  0 1 0 3 2 3 0 0 1 7 ...
## $ YearsWithCurrManager : int  5 7 0 0 2 6 0 0 8 7 ...
```

```
summary(data)
```

```
##      Age      Attrition      BusinessTravel      DailyRate
## Min.   :18.00   No :1233   Non-Travel       : 150   Min.   : 102.0
## 1st Qu.:30.00   Yes: 237   Travel_Frequently: 277   1st Qu.: 465.0
## Median :36.00           Travel_Rarely  :1043   Median : 802.0
## Mean   :36.92                                Mean   : 802.5
## 3rd Qu.:43.00                                3rd Qu.:1157.0
## Max.   :60.00                                Max.   :1499.0
##
##      Department DistanceFromHome Education
## Human Resources      : 63   Min.   : 1.000   Min.   :1.000
## Research & Development:961 1st Qu.: 2.000   1st Qu.:2.000
## Sales                 :446 Median : 7.000   Median :3.000
##                      Mean   : 9.193   Mean   :2.913
##                      3rd Qu.:14.000   3rd Qu.:4.000
##                      Max.   :29.000   Max.   :5.000
##
##      EducationField EmployeeCount EmployeeNumber EnvironmentSatisfaction
## Human Resources : 27   Min.   :1   Min.   : 1.0   Min.   :1.000
## Life Sciences   :606 1st Qu.:1   1st Qu.: 491.2 1st Qu.:2.000
## Marketing       :159 Median :1   Median :1020.5 Median :3.000
## Medical         :464 Mean   :1   Mean   :1024.9 Mean   :2.722
## Other           : 82 3rd Qu.:1   3rd Qu.:1555.8 3rd Qu.:4.000
## Technical Degree:132 Max.   :1   Max.   :2068.0 Max.   :4.000
##
##      Gender      HourlyRate      JobInvolvement      JobLevel
## Female:588   Min.   : 30.00   Min.   :1.00   Min.   :1.000
## Male :882    1st Qu.: 48.00   1st Qu.:2.00   1st Qu.:1.000
##             Median : 66.00   Median :3.00   Median :2.000
##             Mean   : 65.89   Mean   :2.73   Mean   :2.064
##             3rd Qu.: 83.75   3rd Qu.:3.00   3rd Qu.:3.000
```

```

##           Max.      :100.00   Max.      :4.00   Max.      :5.000
##
##           JobRole      JobSatisfaction  MaritalStatus  MonthlyIncome
## Sales Executive      :326   Min.      :1.000   Divorced:327   Min.      : 1009
## Research Scientist    :292   1st Qu.:2.000   Married :673   1st Qu.: 2911
## Laboratory Technician :259   Median :3.000   Single  :470   Median : 4919
## Manufacturing Director :145   Mean    :2.729                      Mean    : 6503
## Healthcare Representative:131   3rd Qu.:4.000                      3rd Qu.: 8379
## Manager              :102   Max.      :4.000                      Max.      :19999
## (Other)              :215
## MonthlyRate  NumCompaniesWorked  Over18  OverTime  PercentSalaryHike
## Min.      : 2094   Min.      :0.000      Y:1470   No :1054   Min.      :11.00
## 1st Qu.: 8047   1st Qu.:1.000                      Yes: 416   1st Qu.:12.00
## Median :14236   Median :2.000                      Median :14.00
## Mean    :14313   Mean    :2.693                      Mean    :15.21
## 3rd Qu.:20462   3rd Qu.:4.000                      3rd Qu.:18.00
## Max.      :26999   Max.      :9.000                      Max.      :25.00
##
## PerformanceRating  RelationshipSatisfaction  StandardHours  StockOptionLevel
## Min.      :3.000   Min.      :1.000      Min.      :80   Min.      :0.0000
## 1st Qu.:3.000   1st Qu.:2.000      1st Qu.:80   1st Qu.:0.0000
## Median :3.000   Median :3.000      Median :80   Median :1.0000
## Mean    :3.154   Mean    :2.712      Mean    :80   Mean    :0.7939
## 3rd Qu.:3.000   3rd Qu.:4.000      3rd Qu.:80   3rd Qu.:1.0000
## Max.      :4.000   Max.      :4.000      Max.      :80   Max.      :3.0000
##
## TotalWorkingYears  TrainingTimesLastYear  WorkLifeBalance  YearsAtCompany
## Min.      : 0.00   Min.      :0.000      Min.      :1.000   Min.      : 0.000
## 1st Qu.: 6.00   1st Qu.:2.000      1st Qu.:2.000   1st Qu.: 3.000
## Median :10.00   Median :3.000      Median :3.000   Median : 5.000
## Mean    :11.28   Mean    :2.799      Mean    :2.761   Mean    : 7.008
## 3rd Qu.:15.00   3rd Qu.:3.000      3rd Qu.:3.000   3rd Qu.: 9.000
## Max.      :40.00   Max.      :6.000      Max.      :4.000   Max.      :40.000
##
## YearsInCurrentRole  YearsSinceLastPromotion  YearsWithCurrManager
## Min.      : 0.000   Min.      : 0.000      Min.      : 0.000
## 1st Qu.: 2.000   1st Qu.: 0.000      1st Qu.: 2.000
## Median : 3.000   Median : 1.000      Median : 3.000
## Mean    : 4.229   Mean    : 2.188      Mean    : 4.123
## 3rd Qu.: 7.000   3rd Qu.: 3.000      3rd Qu.: 7.000
## Max.      :18.000   Max.      :15.000      Max.      :17.000
##

```

Interprétation

Le dataset contient 1470 employés et 35 variables décrivant différentes caractéristiques des employés telles que l'âge, le salaire, le département, le niveau d'éducation et l'attrition.

La variable cible principale est "Attrition", qui indique si l'employé a quitté l'entreprise ou non.

La majorité des employés appartiennent au département Research & Development.

L'âge moyen des employés est d'environ 37 ans.

La majorité des employés ne quittent pas l'entreprise, ce qui montre un faible taux d'attrition.

Présentation du dataset

Le dataset utilisé dans cette étude est le dataset HR Analytics Employee Attrition & Performance.

Il contient des informations relatives aux employés d'une entreprise telles que : - l'âge, - le revenu mensuel, - le département, - le poste occupé, - l'ancienneté, - ainsi que la variable d'attrition.

L'objectif principal est d'analyser les facteurs pouvant influencer le départ des employés.

Description des variables

Le dataset contient 1470 observations et 35 variables.

Parmi les principales variables étudiées :

- Age : âge de l'employé
- MonthlyIncome : revenu mensuel
- Department : département de travail
- JobRole : poste occupé
- Gender : genre de l'employé
- YearsAtCompany : ancienneté dans l'entreprise
- TotalWorkingYears : nombre total d'années d'expérience
- Attrition : indique si l'employé a quitté l'entreprise ou non

Nettoyage et préparation des données

```
sum(is.na(data))
```

```
## [1] 0
```

```
data <- na.omit(data)
```

```
str(data)
```

```
## 'data.frame': 1470 obs. of 35 variables:
## $ Age : int 41 49 37 33 27 32 59 30 38 36 ...
## $ Attrition : Factor w/ 2 levels "No","Yes": 2 1 2 1 1 1 1 1 1 1 ...
## $ BusinessTravel : Factor w/ 3 levels "Non-Travel","Travel_Frequently",...: 3 2 3 2 3 2 3 3 ...
## $ DailyRate : int 1102 279 1373 1392 591 1005 1324 1358 216 1299 ...
## $ Department : Factor w/ 3 levels "Human Resources",...: 3 2 2 2 2 2 2 2 2 ...
## $ DistanceFromHome : int 1 8 2 3 2 2 3 24 23 27 ...
## $ Education : int 2 1 2 4 1 2 3 1 3 3 ...
## $ EducationField : Factor w/ 6 levels "Human Resources",...: 2 2 5 2 4 2 4 2 2 4 ...
## $ EmployeeCount : int 1 1 1 1 1 1 1 1 1 1 ...
## $ EmployeeNumber : int 1 2 4 5 7 8 10 11 12 13 ...
## $ EnvironmentSatisfaction : int 2 3 4 4 1 4 3 4 4 3 ...
## $ Gender : Factor w/ 2 levels "Female","Male": 1 2 2 1 2 2 1 2 2 2 ...
## $ HourlyRate : int 94 61 92 56 40 79 81 67 44 94 ...
## $ JobInvolvement : int 3 2 2 3 3 3 4 3 2 3 ...
## $ JobLevel : int 2 2 1 1 1 1 1 1 3 2 ...
```

```
## $ JobRole : Factor w/ 9 levels "Healthcare Representative",...: 8 7 3 7 3 3 3 5 1
## $ JobSatisfaction : int 4 2 3 3 2 4 1 3 3 3 ...
## $ MaritalStatus : Factor w/ 3 levels "Divorced","Married",...: 3 2 3 2 2 3 2 1 3 2 ...
## $ MonthlyIncome : int 5993 5130 2090 2909 3468 3068 2670 2693 9526 5237 ...
## $ MonthlyRate : int 19479 24907 2396 23159 16632 11864 9964 13335 8787 16577 ...
## $ NumCompaniesWorked : int 8 1 6 1 9 0 4 1 0 6 ...
## $ Over18 : Factor w/ 1 level "Y": 1 1 1 1 1 1 1 1 1 1 ...
## $ OverTime : Factor w/ 2 levels "No","Yes": 2 1 2 2 1 1 2 1 1 1 ...
## $ PercentSalaryHike : int 11 23 15 11 12 13 20 22 21 13 ...
## $ PerformanceRating : int 3 4 3 3 3 3 4 4 4 3 ...
## $ RelationshipSatisfaction: int 1 4 2 3 4 3 1 2 2 2 ...
## $ StandardHours : int 80 80 80 80 80 80 80 80 80 80 ...
## $ StockOptionLevel : int 0 1 0 0 1 0 3 1 0 2 ...
## $ TotalWorkingYears : int 8 10 7 8 6 8 12 1 10 17 ...
## $ TrainingTimesLastYear : int 0 3 3 3 3 2 3 2 2 3 ...
## $ WorkLifeBalance : int 1 3 3 3 3 2 2 3 3 2 ...
## $ YearsAtCompany : int 6 10 0 8 2 7 1 1 9 7 ...
## $ YearsInCurrentRole : int 4 7 0 7 2 7 0 0 7 7 ...
## $ YearsSinceLastPromotion : int 0 1 0 3 2 3 0 0 1 7 ...
## $ YearsWithCurrManager : int 5 7 0 0 2 6 0 0 8 7 ...
```

Interprétation

Le nettoyage des données montre que le dataset ne contient aucune valeur manquante.

La fonction `str(data)` indique que le dataset contient 1470 observations et 35 variables.

Les variables qualitatives sont de type facteur (**Factor**) et les variables quantitatives sont de type numérique (**int**).

Les données sont correctement structurées et prêtes pour l'analyse statistique.

CHAPITRE 1 — Analyse univariée

Ce chapitre présente une analyse descriptive des principales variables du dataset.

L'objectif est de comprendre la distribution des caractéristiques des employés telles que l'âge, le revenu mensuel, le genre, le département et l'attrition.


Distribution de l'âge des employés

Cette partie permet d'étudier la distribution de l'âge des employés au sein de l'entreprise.

```
summary(data$Age)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    18.00   30.00   36.00   36.92   43.00   60.00
```

```
hist(
  data$Age,
  col = "skyblue",
  border = "white",
  main = "Distribution de l'âge des employés",
  xlab = "Age",
  ylab = "Nombre d'employés"
)
```



Interprétation

L'âge des employés varie entre 18 et 60 ans, avec une moyenne de 36.92 ans et une médiane de 36 ans.

L'écart interquartile est de 13 ans ($Q1 = 30$ ans, $Q3 = 43$ ans), ce qui indique une population active relativement homogène et concentrée entre 30 et 43 ans.

L'histogramme montre une distribution légèrement asymétrique à droite, avec une diminution progressive du nombre d'employés aux âges les plus élevés.

Cette tranche d'âge dominante correspond à des employés expérimentés et en milieu de carrière.


Distribution du revenu mensuel

Cette partie permet d'étudier la répartition du revenu mensuel des employés dans l'entreprise.

```
summary(data$MonthlyIncome)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1009   2911   4919   6503   8379   19999
```

```
hist(
  data$MonthlyIncome,
  col = "steelblue",
  border = "white",
  main = "Distribution du revenu mensuel",
  xlab = "Revenu mensuel",
  ylab = "Nombre d'employés"
)
```



Interprétation

Le revenu mensuel des employés varie fortement, entre 1009 et 19999.

La médiane (4919) est nettement inférieure à la moyenne (6503), ce qui confirme une asymétrie à droite due à la présence de hauts salaires minoritaires.

Plus de 75% des employés perçoivent un revenu inférieur à 8379, ce qui indique que la majorité des effectifs occupent des postes à rémunération faible ou moyenne.

Les valeurs élevées correspondent probablement à des employés occupant des postes hiérarchiques supérieurs tels que Manager ou Director.


Répartition des employés selon le genre

Cette partie permet d'analyser la répartition des employés selon leur genre.

```
table(data$Gender)
```

```
##  
## Female    Male  
##      588     882
```

```
barplot(  
  table(data$Gender),  
  col = c("pink", "lightblue"),  
  main = "Répartition par genre",  
  ylab = "Nombre d'employés"  
)
```



Interprétation

Le dataset contient 882 hommes (60%) et 588 femmes (40%).

La population étudiée est donc majoritairement masculine, avec un écart de 20 points de pourcentage entre les deux genres.

Ce déséquilibre devra être pris en compte lors de l'interprétation des analyses liées au genre et à l'attrition.


Répartition de l'attrition

Cette partie permet d'étudier la proportion des employés qui quittent l'entreprise.

```
table(data$Attrition)
```

```
##  
##   No   Yes  
## 1233  237
```

```
barplot(  
  table(data$Attrition),  
  col = c("forestgreen", "firebrick"),  
  main = "Répartition de l'attrition",  
  ylab = "Nombre d'employés"  
)
```



Interprétation

Sur les 1470 employés du dataset, 1233 sont restés dans l'entreprise (No) et 237 ont quitté leur poste (Yes). Cela correspond à un taux d'attrition de 16.1%, ce qui représente une minorité significative méritant une analyse approfondie.

Ce déséquilibre entre les deux classes devra être pris en compte lors de la modélisation prédictive, notamment par des techniques de rééchantillonnage ou de pondération.


Répartition des employés par département

Cette partie permet d'étudier la répartition des employés selon les différents départements de l'entreprise.

```
table(data$Department)
```

```
##  
##      Human Resources Research & Development      Sales  
##              63              961              446
```

```
barplot(  
  table(data$Department),  
  col = c("steelblue", "salmon", "lightgreen"),  
  main = "Répartition des employés par département",  
  ylab = "Nombre d'employés",  
  xlab = "Département",  
  las = 1,  
  cex.names = 0.8  
)
```



Interprétation

Les employés sont inégalement répartis entre les trois départements de l'entreprise.

Le département Research & Development concentre la grande majorité des effectifs avec 961 employés, soit 65.4% du total.

Le département Sales regroupe 446 employés (30.3%), tandis que le département Human Resources est le plus petit avec seulement 63 employés (4.3%).

Cette répartition déséquilibrée devra être prise en compte lors des analyses par département.

CHAPITRE 2 — Analyse bivariée quantitative


Cette partie a pour objectif d'étudier les relations entre plusieurs variables quantitatives du dataset.

Relation entre l'âge et le revenu mensuel

Cette analyse permet d'étudier la relation entre l'âge des employés et leur revenu mensuel.

```
plot(  
  data$Age,  
  data$MonthlyIncome,  
  col = "steelblue",  
  pch = 16,  
  main = "Relation entre l'âge et le revenu mensuel",  
  xlab = "Age",  
  ylab = "Revenu mensuel"  
)
```

Relation entre l'âge et le revenu mensuel



```
cor(data$Age, data$MonthlyIncome)
```

```
## [1] 0.4978546
```

Interprétation

Le graphique montre une relation positive entre l'âge et le revenu mensuel des employés.

Le coefficient de corrélation de Pearson est $r = 0.498$, ce qui indique une corrélation positive modérée et statistiquement significative.

En général, les employés les plus âgés tendent à percevoir un revenu plus élevé, probablement en raison de leur expérience professionnelle et de leur ancienneté accumulée.

Cependant, la dispersion importante des points autour de la tendance générale indique que l'âge seul ne détermine pas le niveau de revenu, d'autres facteurs comme le poste ou le niveau hiérarchique jouant également un rôle important.

Matrice de corrélation des variables quantitatives

Cette partie permet d'étudier les corrélations entre plusieurs variables quantitatives du dataset.

```
vars_quanti <- data[, c(  
  "Age",  
  "MonthlyIncome",
```

```

    "YearsAtCompany",
    "TotalWorkingYears",
    "DistanceFromHome"
  )]

cor(vars_quanti)

```

```

##               Age MonthlyIncome YearsAtCompany TotalWorkingYears
## Age           1.00000000    0.49785457    0.31130877    0.680380536
## MonthlyIncome 0.49785457    1.00000000    0.51428483    0.772893246
## YearsAtCompany 0.31130877    0.51428483    1.00000000    0.628133155
## TotalWorkingYears 0.68038054    0.77289325    0.62813316    1.000000000
## DistanceFromHome -0.00168612   -0.01701444    0.00950772    0.004628426
##               DistanceFromHome
## Age           -0.001686120
## MonthlyIncome -0.017014445
## YearsAtCompany 0.009507720
## TotalWorkingYears 0.004628426
## DistanceFromHome 1.000000000

```

Interprétation

La matrice de corrélation révèle des relations positives significatives entre plusieurs variables.

La corrélation la plus forte est observée entre TotalWorkingYears et MonthlyIncome ($r = 0.77$), suivie de Age et TotalWorkingYears ($r = 0.68$), ce qui est logique puisque les employés plus âgés accumulent naturellement plus d'expérience et perçoivent des revenus plus élevés.

YearsAtCompany est modérément corrélée au revenu mensuel ($r = 0.51$) et à l'expérience totale ($r = 0.63$).

En revanche, DistanceFromHome présente des corrélations quasi nulles avec toutes les autres variables (< 0.02 en valeur absolue), confirmant son indépendance totale vis-à-vis des caractéristiques professionnelles étudiées.

Visualisation de la matrice de corrélation

Cette visualisation permet de représenter graphiquement les corrélations entre les variables quantitatives.


```

library(corrplot)

mat_cor <- cor(vars_quanti)

corrplot(
  mat_cor,
  method = "circle",
  type = "upper",
  tl.col = "black",
  tl.cex = 0.8
)

```



Interprétation

Le graphique confirme visuellement ces résultats. Les cercles bleus foncés et de grande taille illustrent les corrélations les plus fortes entre TotalWorkingYears, MonthlyIncome et Age, formant un bloc cohérent de variables positivement liées.

DistanceFromHome se distingue nettement par des cercles quasi invisibles, traduisant son absence de lien avec les autres variables.

Régression linéaire entre le revenu mensuel et l'ancienneté

Cette analyse vise à étudier la relation entre le revenu mensuel des employés et leur ancienneté dans l'entreprise à l'aide d'une régression linéaire simple.

```
modele <- lm(YearsAtCompany ~ MonthlyIncome, data = data)
summary(modele)
```

```
##
## Call:
## lm(formula = YearsAtCompany ~ MonthlyIncome, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.782  -3.074  -0.656   2.517  30.443
##
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.656e+00  2.338e-01  11.36  <2e-16 ***
## MonthlyIncome 6.693e-04  2.913e-05  22.98  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.256 on 1468 degrees of freedom
## Multiple R-squared:  0.2645, Adjusted R-squared:  0.264
## F-statistic: 527.9 on 1 and 1468 DF,  p-value: < 2.2e-16
```

Interprétation

Le modèle de régression linéaire explique l'ancienneté (YearsAtCompany) par le revenu mensuel (MonthlyIncome).

Le coefficient associé à MonthlyIncome est positif (6.693e-04) et hautement significatif (p-value < 2e-16), confirmant qu'un revenu plus élevé est associé à une ancienneté plus importante.

Cependant, le $R^2 = 0.264$ indique que seulement 26.4% de la variation de l'ancienneté est expliquée par le revenu seul. Les 73.6% restants dépendent d'autres facteurs non inclus dans ce modèle.


Visualisation de la régression linéaire

Cette figure représente graphiquement la relation entre le revenu mensuel et l'ancienneté des employés.

```
plot(
  data$MonthlyIncome,
  data$YearsAtCompany,
  col = "steelblue",
  pch = 16,
  xlab = "Revenu mensuel",
  ylab = "Ancienneté dans l'entreprise",
  main = "Régression linéaire : ancienneté ~ revenu"
)

abline(modele, col = "red", lwd = 2)
```


Régression linéaire : ancienneté ~ revenu



Interprétation

La droite de régression croissante confirme la relation positive entre le revenu mensuel et l'ancienneté dans l'entreprise.

Cependant, la forte dispersion des points autour de la droite illustre les limites du modèle : le revenu mensuel ne suffit pas à lui seul à expliquer l'ancienneté des employés, ce que confirme le $R^2 = 0.264$.

Intervalle de confiance du revenu mensuel

Cette partie permet d'estimer l'intervalle dans lequel se situe la moyenne réelle du revenu mensuel des employés avec un niveau de confiance de 95 %.

```
t.test(data$MonthlyIncome)
```

```
##
## One Sample t-test
##
## data: data$MonthlyIncome
## t = 52.958, df = 1469, p-value < 2.2e-16
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
## 6262.063 6743.800
## sample estimates:
## mean of x
## 6502.931
```

Interprétation

Le test t appliqué à la variable `MonthlyIncome` permet d'estimer l'intervalle de confiance à 95% de la moyenne salariale de l'entreprise.

Avec un niveau de confiance de 95%, la moyenne du revenu mensuel est comprise entre 6262 et 6744, avec une moyenne estimée de 6503.

La faible largeur de cet intervalle (482 unités, soit $\pm 3.7\%$ de la moyenne) est principalement due à la grande taille de l'échantillon ($n = 1470$), qui réduit l'erreur standard de la moyenne, et non à une faible variabilité des salaires.

Cette estimation fournit néanmoins une référence fiable pour caractériser le niveau salarial global de l'entreprise.

Estimation locale de densité : Âge et revenu mensuel


Cette partie permet de visualiser les zones où les employés sont les plus concentrés selon leur âge et leur revenu mensuel.

```
library(MASS)

tmp <- data[, c("Age", "MonthlyIncome")]
tmp <- tmp[complete.cases(tmp), ]

filled.contour(
  kde2d(tmp$Age, tmp$MonthlyIncome),
  color.palette = terrain.colors,
  xlab = "Âge",
  ylab = "Revenu mensuel",
  main = "Estimation locale de densité : Age × Revenu"
)
```

Estimation locale de densité : Age × Revenu



Interprétation

Le graphique de densité bidimensionnelle met en évidence les zones de concentration des employés selon leur âge et leur revenu mensuel.

La densité maximale est observée chez les employés âgés entre 25 et 40 ans avec un revenu compris entre 2000 et 5000, correspondant aux profils les plus représentés dans l'entreprise, probablement des postes d'entrée ou de milieu de gamme.

Les zones de faible densité correspondent aux employés avec des revenus très élevés ou des âges avancés, qui sont minoritaires dans l'entreprise.

Cette représentation confirme l'existence d'une relation positive modérée entre l'âge et le revenu mensuel, tout en montrant que les hauts revenus restent rares à tous les âges.

CHAPITRE 3 — Analyse bivariée qualitative

Cette partie a pour objectif d'étudier les relations entre deux variables qualitatives du dataset afin d'identifier d'éventuelles dépendances entre celles-ci.

Attrition vs Département

Cette analyse permet d'étudier s'il existe une relation entre le département de l'employé et sa décision de quitter l'entreprise.

```
table(data$Attrition, data$Department)
```

```
##
##      Human Resources Research & Development Sales
##   No           51              828      354
##   Yes           12              133      92
```

```
chisq.test(data$Attrition, data$Department)
```

```
##
##  Pearson's Chi-squared test
##
## data:  data$Attrition and data$Department
## X-squared = 10.796, df = 2, p-value = 0.004526
```

Interprétation

Le tableau de contingence révèle des taux d'attrition différents selon les départements.

Le département Sales présente le taux d'attrition le plus élevé avec 92 départs sur 446 employés, soit 20.6%.

Le département Human Resources affiche un taux d'attrition de 19% (12 départs sur 63 employés), tandis que Research & Development présente le taux le plus faible avec 13.8% (133 départs sur 961 employés).

Le test du Khi-deux de Pearson donne une p-value de 0.0045, largement inférieure au seuil de 0.05.

On rejette donc l'hypothèse d'indépendance entre les deux variables : il existe une relation statistiquement significative entre le département et l'attrition. Le département d'appartenance influence donc la probabilité de quitter l'entreprise.

Attrition vs Genre

Cette analyse vise à vérifier si le genre influence la décision de quitter l'entreprise.

```
table(data$Attrition, data$Gender)
```

```
##
##      Female Male
##   No      501  732
##   Yes      87  150
```

```
chisq.test(data$Attrition, data$Gender)
```

```
##
##  Pearson's Chi-squared test with Yates' continuity correction
##
## data:  data$Attrition and data$Gender
## X-squared = 1.117, df = 1, p-value = 0.2906
```

Interprétation

Le tableau de contingence montre des taux d'attrition proches entre les deux genres : 14.8% chez les femmes (87 départs sur 588) et 17% chez les hommes (150 départs sur 882).

Le test du Khi-deux de Pearson avec correction de Yates donne une p-value de 0.2906, supérieure au seuil de 0.05.

On ne rejette donc pas l'hypothèse d'indépendance entre les deux variables : il n'existe pas de relation statistiquement significative entre le genre et l'attrition dans cet échantillon.

Attrition vs Business Travel

Cette analyse permet d'étudier si les déplacements professionnels influencent la décision de quitter l'entreprise.

```
table(data$Attrition, data$BusinessTravel)
```

```
##
##      Non-Travel Travel_Frequently Travel_Rarely
##   No          138             208             887
##   Yes           12              69             156
```

```
chisq.test(data$Attrition, data$BusinessTravel)
```

```
##
##  Pearson's Chi-squared test
##
## data:  data$Attrition and data$BusinessTravel
## X-squared = 24.182, df = 2, p-value = 5.609e-06
```

Interprétation

Le tableau de contingence révèle des différences marquées selon la fréquence des déplacements professionnels.

Les employés voyageant fréquemment (Travel_Frequently) présentent le taux d'attrition le plus élevé avec 69 départs sur 277 employés, soit 24.9%.

Les employés voyageant rarement affichent un taux intermédiaire de 15% (156/1043), tandis que les employés sans déplacement (Non-Travel) présentent le taux le plus faible avec seulement 8% (12/150).

Le test du Khi-deux donne une p-value de 5.609e-06, très largement inférieure au seuil de 0.05.

On rejette donc l'hypothèse d'indépendance : la fréquence des déplacements professionnels est significativement associée à l'attrition. Plus un employé voyage fréquemment, plus son risque de quitter l'entreprise est élevé.

Test de Fisher

Ce test est utilisé lorsque les effectifs sont faibles.

```
fisher.test(data$Attrition, data$Gender)
```

```
##
## Fisher's Exact Test for Count Data
##
## data: data$Attrition and data$Gender
## p-value = 0.2778
## alternative hypothesis: true odds ratio is not equal to 1
## 95 percent confidence interval:
## 0.8775556 1.5933584
## sample estimates:
## odds ratio
## 1.179913
```

Interprétation

Le test exact de Fisher a été appliqué en complément du test du Khi-deux pour analyser la relation entre le genre et l'attrition.

La p-value obtenue est de 0.2778, supérieure au seuil de 0.05. On ne rejette donc pas l'hypothèse d'indépendance entre les deux variables, ce qui confirme les résultats du test du Khi-deux.

De plus, l'odds ratio estimé est de 1.18, avec un intervalle de confiance à 95% de [0.878 ; 1.593] qui contient la valeur 1, confirmant l'absence d'effet significatif du genre sur la probabilité de quitter l'entreprise.

Analyse des correspondances (AFC)

Cette méthode permet de visualiser les relations entre les modalités des variables qualitatives.

```
library(FactoMineR)
library(factoextra)
data_clean <- na.omit(data[, c("Attrition", "JobRole")])
t_afc <- table(data_clean$Attrition, data_clean$JobRole)
t_afc
```

```
##
##      Healthcare Representative Human Resources Laboratory Technician Manager
## No      122      40      197      97
## Yes      9      12      62      5
##
##      Manufacturing Director Research Director Research Scientist
## No      135      78      245
## Yes      10      2      47
##
##      Sales Executive Sales Representative
## No      269      50
## Yes      57      33
```

```
resultat_afc <- CA(t_afc, graph = TRUE)
```

Interprétation

L'Analyse des Correspondances (AFC) permet de visualiser les associations entre les modalités de l'attrition et les différents postes occupés par les employés. Les résultats montrent des disparités importantes selon le poste occupé.

Le Sales Representative présente le taux d'attrition le plus élevé avec 33 départs sur 83 employés, soit 39.8%, suivi du Laboratory Technician avec 62 départs sur 259 employés, soit 23.9%.

À l'inverse, les postes de Manager ($5/102 = 4.9\%$), Manufacturing Director ($10/145 = 6.9\%$) et Research Director ($2/80 = 2.5\%$) présentent des taux d'attrition très faibles, indiquant une forte stabilité de ces profils au sein de l'entreprise.


Cette analyse met en évidence que le type de poste occupé est fortement associé au risque de départ, ce qui peut aider l'entreprise à mieux cibler ses politiques de rétention vers les postes les plus exposés.

CHAPITRE 4 — Analyse bivariée mixte (quant + quali)

Cette partie a pour objectif d'étudier les relations entre les variables quantitatives et qualitatives du dataset.

Relation entre MonthlyIncome et Department

```
boxplot(  
  MonthlyIncome ~ Department,  
  data = data,  
  col = c("steelblue", "salmon", "forestgreen"),  
  main = "Revenu mensuel par département",  
  xlab = "Département",  
  ylab = "Revenu mensuel ($)"  
)
```



Interprétation

Le graphique boxplot montre des distributions salariales différentes selon les départements.

Le département Research & Development présente les revenus mensuels médians les plus élevés, suivi du département Sales, tandis que Human Resources affiche les revenus les plus faibles.

Des valeurs extrêmes (outliers) sont observées dans les trois départements, correspondant à des employés occupant des postes à très hautes responsabilités.

Le test ANOVA confirme cette différence avec une p-value de 0.041, inférieure au seuil de 0.05. Cependant, cette p-value est à peine significative, ce qui indique que l'effet du département sur le revenu mensuel, bien que réel, reste modeste.

Relation entre Age et Attrition

```
boxplot(
  Age ~ Attrition,
  data = data,
  col = c("forestgreen", "firebrick"),
  main = "Âge selon l'attrition",
  xlab = "Attrition",
  ylab = "Âge"
)
```




Interprétation

Le graphique boxplot révèle une différence d'âge notable entre les employés ayant quitté l'entreprise et ceux qui y sont restés.

La médiane d'âge des employés sans attrition (No) est d'environ 37 ans, contre environ 33 ans pour les employés ayant quitté l'entreprise (Yes), soit une différence de 4 ans.

Les employés qui quittent l'entreprise sont donc globalement plus jeunes, ce qui suggère que les profils juniors sont plus susceptibles de partir, possiblement en raison de meilleures opportunités externes ou d'une moindre ancienneté.

ANOVA : MonthlyIncome ~ Department

```
anova_dept <- aov(MonthlyIncome ~ Department, data = data)
```

```
summary(anova_dept)
```

```
##              Df    Sum Sq Mean Sq F value Pr(>F)
## Department    2 1.415e+08  70754962   3.202  0.041 *
## Residuals  1467 3.242e+10  22098613
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interprétation

Le test ANOVA compare les revenus mensuels moyens entre les trois départements.

La p-value obtenue (0.041) est inférieure au seuil de 0.05, on rejette donc l'hypothèse d'égalité des moyennes : le revenu mensuel varie significativement selon le département.

Cependant, cette p-value est à peine significative et la statistique $F = 3.202$ reste modeste, ce qui indique que l'effet du département sur le revenu, bien que réel, demeure faible. D'autres facteurs comme le poste occupé ou le niveau hiérarchique expliquent davantage les différences salariales observées.

ANOVA : Age ~ Attrition

```
anova_attr <- aov(Age ~ Attrition, data = data)
summary(anova_attr)
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## Attrition      1   3107   3107.3    38.18 8.36e-10 ***
## Residuals    1468 119488     81.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interprétation

Le test ANOVA confirme de manière très significative la différence d'âge moyen entre les deux groupes d'attrition.

La statistique $F = 38.18$ et la p-value de $8.36e-10$ sont extrêmement significatives, bien en dessous du seuil de 0.001.

On rejette donc l'hypothèse d'égalité des moyennes d'âge entre les deux groupes : l'âge influence significativement l'attrition des employés.

Ce résultat est l'un des plus robustes de l'étude et confirme que les jeunes employés quittent plus fréquemment l'entreprise que leurs collègues plus expérimentés.

CHAPITRE 5 — Analyse multivariée

Analyse en composantes principales (ACP)

Cette partie permet de réduire la dimension des variables quantitatives et d'identifier les principales relations entre elles.

Importation des bibliothèques


```
library(FactoMineR)
library(factoextra)
```


Sélection des variables quantitatives

```
vars_quanti <- data[, c(
  "Age",
  "MonthlyIncome",
  "YearsAtCompany",
  "TotalWorkingYears",
  "DistanceFromHome"
)]
```

Réalisation de l'ACP

```
resultat_pca <- PCA(vars_quanti,
  scale.unit = TRUE,
  graph = TRUE)
```





Interprétation générale

L'ACP permet de réduire la dimension des données quantitatives et d'identifier les principales relations entre les variables étudiées.

Les graphiques obtenus représentent les individus et les variables selon les principales composantes de l'analyse.

Valeurs propres

```
eig.val <- get_eigenvalue(resultat_pca)
```

```
eig.val
```

##	eigenvalue	variance.percent	cumulative.variance.percent
## Dim.1	2.7288144	54.576288	54.57629
## Dim.2	1.0007100	20.014200	74.59049
## Dim.3	0.6909004	13.818009	88.40850
## Dim.4	0.4236736	8.473472	96.88197
## Dim.5	0.1559016	3.118031	100.00000

Interprétation des valeurs propres

La première composante principale explique environ 54.6 % de la variance totale des données.


La deuxième composante explique environ 20 % de la variance. Ainsi, les deux premières composantes expliquent ensemble près de 74.6 % de l'information totale.

Cela montre que les deux premières dimensions résument efficacement les variables quantitatives étudiées et conservent une grande partie de l'information du dataset.

Les autres composantes expliquent une part plus faible de la variance, ce qui indique qu'elles apportent moins d'information supplémentaire.

Visualisation des valeurs propres

```
fviz_eig(resultat_pca,  
        addlabels = TRUE,  
        ylim = c(0, 60))
```




Interprétation

Le scree plot montre une forte diminution après les deux premières composantes principales.

Cela indique que les deux premières dimensions sont les plus importantes pour représenter les données.

Les autres composantes apportent moins d'information supplémentaire.


```
gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
repel = TRUE)
```



Interprétation du graphique des variables

Age, MonthlyIncome, TotalWorkingYears et YearsAtCompany sont orientées dans la même direction sur Dim1, avec des flèches longues confirmant leur forte contribution et leurs corrélations positives entre elles. Dim1 représente ainsi un axe de séniorité et d'expérience.

DistanceFromHome est orientée vers le haut sur Dim2, perpendiculairement aux autres variables, traduisant son indépendance totale vis-à-vis des autres caractéristiques. Dim2 capte principalement la mobilité géographique.

CHAPITRE 6 — Analyse factorielle des données mixtes (FAMD)

Ce chapitre présente une analyse factorielle des données mixtes (FAMD) permettant d'étudier simultanément les variables quantitatives et qualitatives du dataset.


L'objectif est d'identifier les principales relations entre les caractéristiques des employés et l'attrition.


Sélection des variables


```
vars_famd <- data[, c(  
  "Age",  
  "MonthlyIncome",  
  "YearsAtCompany",  
  "Department",  
  "Gender",  
  "Attrition",  
  "BusinessTravel"  
)]
```


Réalisation de la FAMD

```
library(FactoMineR)  
library(factoextra)  
  
resultat_famd <- FAMD(vars_famd,  
  graph = TRUE)
```









Interprétation générale

La FAMD permet d'analyser simultanément les variables quantitatives et qualitatives du dataset.

Cette méthode permet de visualiser les relations entre les employés, les variables et les différentes catégories étudiées.

Valeurs propres

```
eig_famd <- get_eigenvalue(resultat_famd)
eig_famd
```

##	eigenvalue	variance.percent	cumulative.variance.percent
## Dim.1	1.967369	21.85965	21.85965
## Dim.2	1.129141	12.54601	34.40566
## Dim.3	1.046484	11.62760	46.03326
## Dim.4	1.013889	11.26543	57.29869
## Dim.5	1.002266	11.13628	68.43498


Interprétation des valeurs propres

La première dimension explique 21.9% de la variance et la deuxième 12.5%, soit seulement 34.4% cumulés pour les deux premières dimensions.

Contrairement à l'ACP, les dimensions 2 à 5 ont des contributions très proches (entre 11.1% et 12.5%), ce qui indique qu'aucune dimension ne domine clairement. Il faudrait conserver 5 dimensions pour atteindre 68.4% de variance expliquée, ce qui reflète la complexité des données mixtes.

Visualisation des valeurs propres

```
fviz_eig(resultat_famd,  
        addlabels = TRUE,  
        ylim = c(0, 50))
```




Interprétation

Le scree plot confirme la décroissance progressive des valeurs propres après Dim1.

Contrairement à un coude net, la courbe descend doucement, indiquant qu'aucune dimension ne capture à elle seule l'essentiel de l'information. Cela reflète la nature complexe des données mixtes où l'information est répartie sur plusieurs dimensions.

Graphique des variables

```
fviz_famd_var(resultat_famd,
              repel = TRUE)
```



Interprétation


Age, MonthlyIncome et YearsAtCompany contribuent fortement à Dim1, confirmant leur rôle dans la caractérisation du profil socio-économique des employés.

Les variables qualitatives BusinessTravel et Attrition contribuent davantage à Dim2, suggérant que cette dimension capte principalement le risque de départ et la mobilité professionnelle.

Gender présente une faible contribution aux deux dimensions, ce qui est cohérent avec l'absence de relation significative entre le genre et l'attrition montrée précédemment.

Graphique des individus

```
fviz_famd_ind(resultat_famd,
              habillage = "Attrition",
              addEllipses = TRUE,
              repel = TRUE)
```



Interprétation

Les deux dimensions expliquent 34.4% de la variance totale, ce qui est modéré mais attendu pour des données mixtes.

Les employés ayant quitté l'entreprise (Yes) tendent à se concentrer dans la partie supérieure du graphique, correspondant aux profils plus jeunes avec des revenus faibles et des déplacements fréquents. Les employés restés (No) dominent la partie inférieure, correspondant aux profils plus seniors et mieux rémunérés.

Cependant, le chevauchement important entre les deux ellipses indique que la séparation n'est pas nette, suggérant qu'aucune combinaison simple de variables ne distingue parfaitement les deux groupes.

Conclusion

La FAMD a permis d'étudier simultanément les variables quantitatives et qualitatives du dataset HR Analytics.

Les résultats montrent que certaines caractéristiques comme le revenu, l'ancienneté, le département et les déplacements professionnels sont liées à l'attrition des employés.

Cette analyse permet ainsi de mieux comprendre les profils des employés susceptibles de quitter l'entreprise.

Conclusion générale

Cette étude statistique réalisée sur le dataset HR Analytics Employee Attrition & Performance a permis d'identifier les principaux facteurs associés au départ des employés.

L'analyse univariée a révélé un taux d'attrition global de 16.1% et mis en évidence des caractéristiques générales de la population : des employés majoritairement masculins (60%), âgés en moyenne de 37 ans, avec des revenus concentrés dans les tranches basses et moyennes.

L'analyse bivariée quantitative a confirmé des corrélations positives significatives entre l'âge, l'expérience, l'ancienneté et le revenu mensuel, la corrélation la plus forte étant observée entre TotalWorkingYears et MonthlyIncome ($r = 0.77$).

L'analyse bivariée qualitative a mis en évidence les facteurs discriminants les plus importants : les déplacements professionnels fréquents sont associés à un taux d'attrition de 24.9%, contre 8% pour les employés sans déplacement. Le département Sales présente le taux d'attrition le plus élevé (20.6%), et certains postes comme Sales Representative (39.8%) sont particulièrement exposés au risque de départ.

L'analyse mixte a confirmé que les employés quittant l'entreprise sont en moyenne 4 ans plus jeunes que ceux qui restent (33 ans contre 37 ans), une différence hautement significative ($p < 0.001$).

Enfin, les méthodes multivariées ACP et FAMD ont permis de synthétiser ces résultats et de visualiser les profils à risque : les employés jeunes, avec un faible revenu, peu d'ancienneté et des déplacements fréquents constituent le profil type le plus exposé à l'attrition.

Ces résultats peuvent aider l'entreprise à mieux cibler ses politiques de rétention, notamment en direction des jeunes employés, des postes de Sales Representative et des employés soumis à des déplacements professionnels fréquents.